Tugas Praktikum 2: Praproses Data

Nama Rasya Arya Ramadhan

NRP 5054251019

Mata Kuliah Data Mining

Deskripsi Dataset

Dataset yang digunakan pada praktikum ini adalah **House Prices - Advanced Regression Techniques** (berkas *train.csv*) dari kompetisi Kaggle. Dataset ini berisi data transaksi rumah di Ames, Iowa, dengan dimensi awal **1.460 baris dan 81 kolom**. Atribut yang tersedia terdiri dari data numerik dan kategorikal yang menjelaskan karakteristik fisik rumah, ditambah satu variabel target yaitu *SalePrice* (harga jual). Praproses data dilakukan agar dataset ini siap dipakai pada tahap pemodelan berikutnya, meliputi pembersihan data, transformasi data, dan reduksi dimensi.

1. Pembersihan Data (Data Cleaning)

Langkah pertama adalah memeriksa nilai hilang (*missing values*) pada seluruh atribut. Atribut dengan proporsi nilai hilang lebih dari 50% dihapus karena informasinya sudah terlalu sedikit untuk digunakan. Terdapat 5 atribut yang memenuhi kondisi tersebut, seperti pada Tabel 1.

Atribut	Jumlah Missing	Persentase (%)
PoolQC	1453	99,52
MiscFeature	1406	96,30
Alley	1369	93,77
Fence	1179	80,75
MasVnrType	872	59,73

Tabel 1. Atribut dengan proporsi missing value lebih dari 50%.

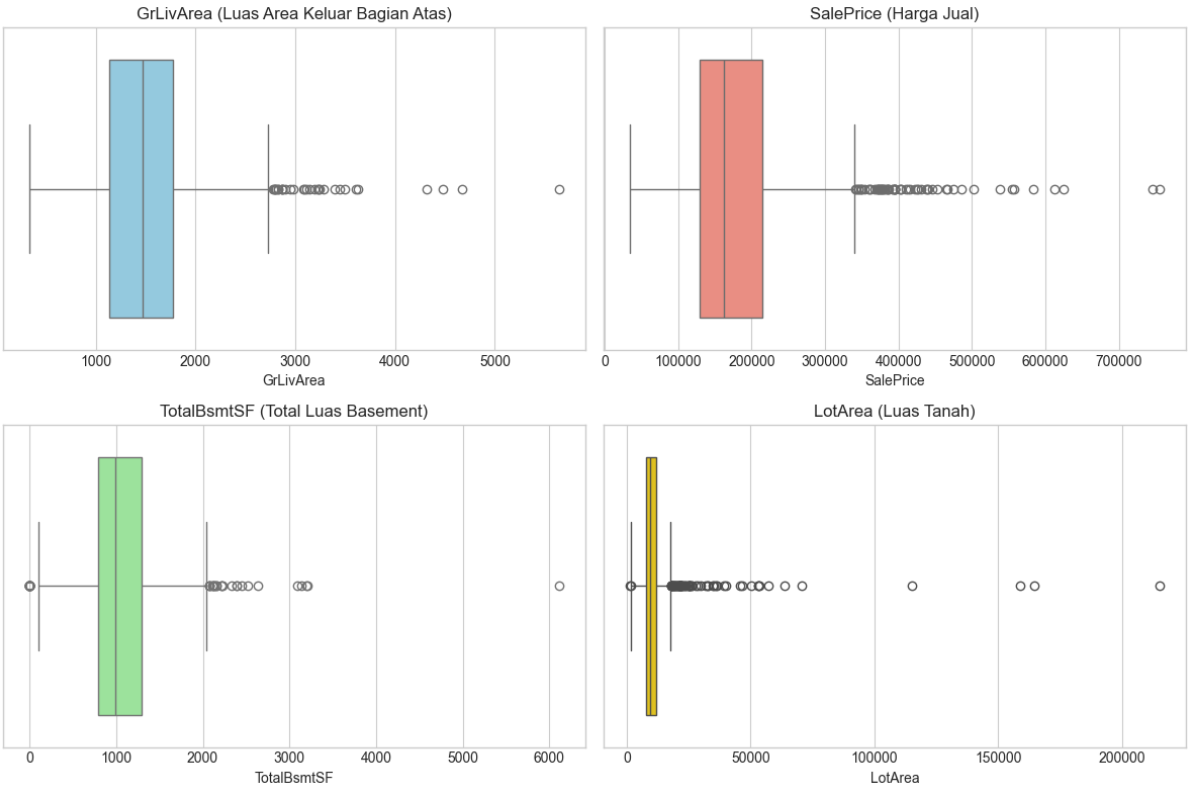
Setelah kelima atribut tersebut dihapus, dimensi dataset menjadi 1.460 baris x 76 kolom. Sisa nilai hilang pada atribut lain diisi (imputasi) sesuai dengan jenis dan konteks datanya, dengan rincian sebagai berikut.

- **BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2, FireplaceQu, GarageType, GarageFinish, GarageQual, GarageCond**: diisi dengan kategori "None", karena nilai hilang pada atribut ini artinya rumah tersebut memang tidak memiliki fasilitas basement, perapian, atau garasi, bukan data yang hilang begitu saja.
- **GarageYrBlt**: diisi dengan nilai 0, sejalan dengan rumah yang tidak memiliki garasi.
- **LotFrontage**: diisi dengan nilai median dari kelompok *Neighborhood* (lingkungan) yang sama, karena luas frontage lahan biasanya dipengaruhi oleh lokasi lingkungan rumah berada. Sisa nilai yang masih kosong diisi dengan median keseluruhan.
- **MasVnrArea**: diisi dengan nilai 0, dengan asumsi rumah tersebut tidak memiliki lapisan veneer batu (*masonry veneer*).
- **Electrical**: diisi dengan nilai modus (nilai yang paling sering muncul), karena hanya ada satu baris data yang kosong pada atribut kategorikal ini.

Setelah semua langkah imputasi selesai, jumlah total nilai hilang pada dataset diverifikasi kembali dan hasilnya adalah **0**, sehingga dataset sudah bersih dari missing value.

2. Deteksi dan Penanganan Outlier

Deteksi outlier dilakukan secara visual dengan boxplot pada empat atribut numerik utama, yaitu *GrLivArea*, *SalePrice*, *TotalBsmtSF*, dan *LotArea*, seperti pada Gambar 1.



Gambar 1. Boxplot atribut GrLivArea, SalePrice, TotalBsmtSF, dan LotArea.

Berdasarkan dokumentasi resmi dataset Ames Housing (De Cock, 2011), ada 2 observasi pada atribut *GrLivArea* dengan luas di atas 4.000 kaki persegi tetapi harga jualnya di bawah 300.000 dolar, seperti pada Tabel 2.

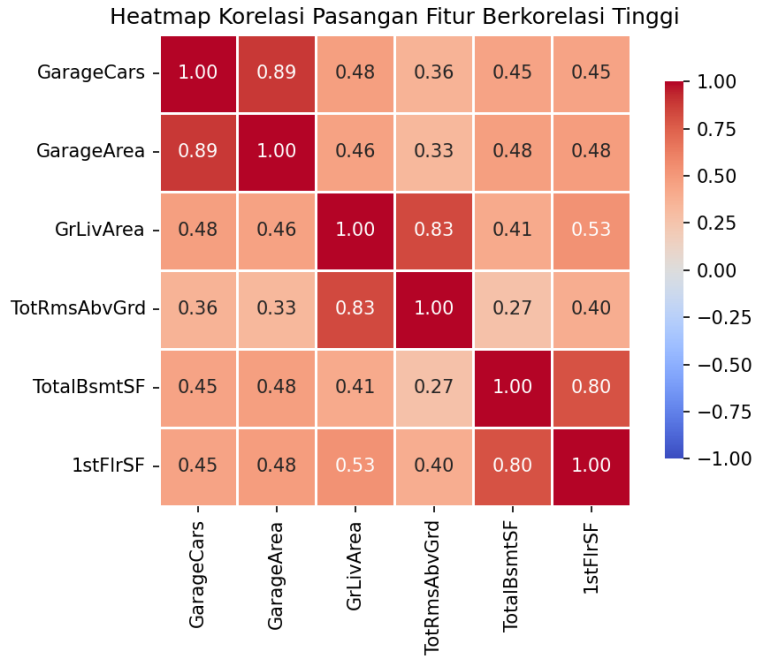
Id	GrLivArea	SalePrice
524	4676	184.750
1299	5642	160.000

Tabel 2. Observasi outlier pada atribut GrLivArea.

Kedua rumah tersebut memiliki luas area yang sangat besar tetapi dijual dengan harga yang jauh lebih rendah dari yang seharusnya, sehingga dianggap sebagai outlier yang tidak wajar dan dapat mengganggu analisis maupun estimasi model. Karena itu, kedua baris data tersebut dihapus, sehingga dimensi dataset menjadi **1.458 baris x 76 kolom**.

3. Transformasi Data

a. Eliminasi Fitur Redundan. Untuk mengurangi multikolinearitas, dilakukan pengecekan korelasi Pearson antar atribut numerik. Ditemukan tiga pasangan atribut dengan koefisien korelasi di atas 0,80, yaitu *TotalBsmtSF* dengan *1stFlrSF* (0,8038), *GrLivArea* dengan *TotRmsAbvGrd* (0,8295), dan *GarageCars* dengan *GarageArea* (0,8873). Dari setiap pasangan tersebut, satu atribut dibuang agar tidak terjadi redundansi informasi, yaitu *GarageArea*, *TotRmsAbvGrd*, dan *1stFlrSF*. Setelah eliminasi ini, dimensi dataset menjadi **1.458 baris x 73 kolom**.



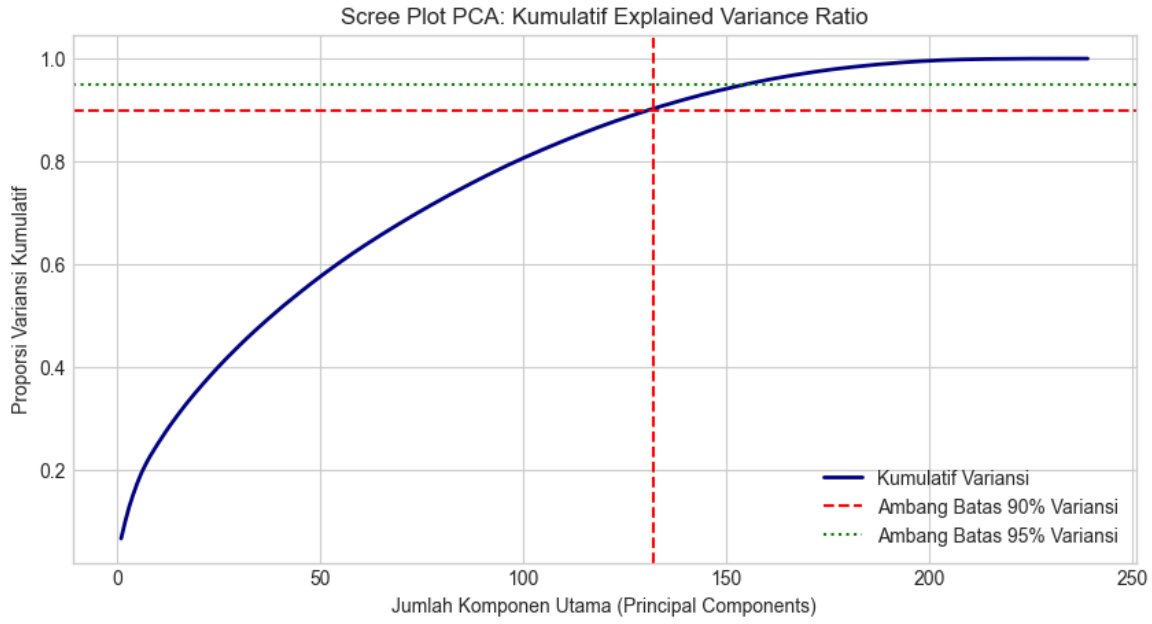
Gambar 2. Heatmap korelasi pasangan fitur berkorelasi tinggi (GarageCars-GarageArea, GrLivArea-TotRmsAbvGrd, TotalBsmtSF-1stFlrSF), dihitung dari train.csv dengan pipeline praproses yang sama seperti pada notebook.

b. One-Hot Encoding. Variabel kategorikal diubah menjadi bentuk biner (0 dan 1) dengan fungsi *pd.get_dummies()* dan opsi *drop_first=True* agar tidak ada duplikasi informasi antar kategori. Hasil encoding ini menghasilkan matriks fitur dengan total **239 fitur**.

c. Standarisasi Fitur. Seluruh fitur numerik hasil encoding kemudian distandarisasi dengan *StandardScaler* agar memiliki rata-rata (mean) 0 dan varians 1. Hasilnya adalah matriks fitur berdimensi **1.458 baris x 239 kolom** yang siap dipakai pada tahap reduksi dimensi.

4. Reduksi Dimensi (Principal Component Analysis)

PCA dipakai untuk mengompresi 239 fitur hasil standarisasi menjadi sejumlah komponen utama yang saling ortogonal, dengan tetap mempertahankan sebagian besar variansi data. Kurva kumulatif variansi terjelaskan ditampilkan pada Gambar 3.



Gambar 3. Scree plot PCA, kurva kumulatif explained variance ratio.

Dari total 239 komponen utama yang tersedia, diperoleh **132 komponen** yang mampu mempertahankan 90% variansi data, dan **155 komponen** untuk mempertahankan 95% variansi data. Pada praktikum ini dipakai ambang batas 90% variansi, sehingga dataset direduksi menjadi 132 komponen utama (PC1 sampai PC132). Dataset akhir kemudian disusun dengan menggabungkan kolom *Id*, 132 komponen utama hasil PCA, dan variabel target *SalePrice*, sehingga dimensi akhirnya adalah **1.458 baris x 134 kolom**.

5. Ringkasan Dataset Akhir

Tabel 3 merangkum perubahan dimensi dataset pada setiap tahap praproses, mulai dari dataset awal sampai dataset akhir yang siap dipakai untuk pemodelan.

Tahap	Dimensi Dataset
Dataset awal	1.460 baris x 81 kolom
Setelah penghapusan kolom missing > 50%	1.460 baris x 76 kolom
Setelah penghapusan outlier GrLivArea	1.458 baris x 76 kolom
Setelah eliminasi fitur redundan (korelasi > 0,80)	1.458 baris x 73 kolom
Setelah one-hot encoding	1.458 baris x 239 kolom (fitur)
Setelah PCA (90% variansi)	1.458 baris x 134 kolom

Tabel 3. Ringkasan dimensi dataset pada setiap tahap praproses, dari 1.460 baris x 81 kolom menjadi 1.458 baris x 134 kolom.

6. Kesimpulan

Praproses data pada dataset House Prices mengubah dataset awal berdimensi 1.460 baris x 81 kolom menjadi dataset akhir berdimensi 1.458 baris x 134 kolom. Selama prosesnya, dataset sudah tidak memiliki missing value, 2 outlier ekstrem pada GrLivArea sudah dihapus, dan 3 fitur yang redundan karena korelasi tinggi juga sudah dibuang. Dataset kemudian melalui proses one-hot encoding, standarisasi, dan reduksi dimensi dengan PCA. Hasil akhirnya adalah 132 komponen utama yang masih menyimpan 90% variansi data asli, jauh lebih ringkas dibandingkan 239 fitur hasil encoding, sehingga dataset ini lebih efisien dipakai pada tahap pemodelan prediksi harga rumah selanjutnya.