LAPORAN PRAKTIKUM DATA MINING
Web Scraping dan Exploratory Data Analysis (EDA)

Studi Kasus: Hasil 83rd Comrades Marathon – Up Run 2008 (DUV Ultra Marathon Statistics)

Nama : Rasya Arya Ramadhan
NRP : 5054251019

I. Deskripsi Dataset dan Metodologi Pengumpulan Data

Data yang digunakan dalam praktikum ini diambil dari basis data publik DUV Ultra Marathon Statistics (statistik.d-u-v.org), dengan fokus pada hasil perlombaan 83rd Comrades Marathon – Up Run tahun 2008 (jarak tempuh 87 km, nomor identifikasi event: 1456). Halaman web sumber menyajikan data dalam bentuk tabel HTML statis berbasis server.

Pengambilan data dilakukan menggunakan pustaka Python requests untuk permintaan HTTP dan BeautifulSoup untuk penguraian elemen tabel. Proses perayapan data memperhatikan ketentuan etika: berkas robots.txt server mengembalikan kode status HTTP 404 (tidak terdapat restriksi perayapan), dokumen HTML menyertakan tag meta name="robots" content="INDEX,FOLLOW", serta skrip menyematkan parameter timeout dan header User-Agent yang transparan. Seluruh data mentah disimpan secara lokal ke dalam berkas dataset_raw_comrades_marathon.csv sejumlah 2.000 baris data unik pelari tanpa proses penarikan ulang.

Dataset memiliki 12 atribut yang mencakup seluruh skala pengukuran data standar, sebagaimana dirangkum pada Tabel 1.

Atribut	Tipe Asal	Skala Pengukuran	Definisi Operasional
rank	int64	Numerik Diskrit	Urutan posisi finish keseluruhan (1–2.000)
performance_time	object	Numerik Kontinu	Waktu tempuh riil, dikonversi ke total menit
athlete_name	object	Kategorikal Nominal	Nama lengkap pelari
club	object	Kategorikal Nominal	Nama klub atletik yang menaungi pelari
nationality	object	Kategorikal Nominal	Kode ISO 3 huruf negara asal atlet
year_of_birth	int64	Numerik Diskrit	Tahun kelahiran, ditransformasikan menjadi usia saat event
gender	object	Kategorikal Nominal	Jenis kelamin (M = Laki-laki, F = Perempuan)
gender_rank	int64	Numerik Diskrit	Peringkat finish dalam kelompok gender

age_category	object	Kategorikal Ordinal	Kelompok usia resmi lomba (M23, M35, M40, dst.)
category_rank	int64	Numerik Diskrit	Peringkat finish dalam kelompok usia spesifik
Atribut	**Tipe Asal**	**Skala Pengukuran**	**Definisi Operasional**
avg_speed_kmh	float64	Numerik Kontinu	Kecepatan rata-rata lomba (km/jam)
age_graded_performance	object	Numerik Kontinu	Waktu tempuh hasil normalisasi faktor usia (menit)

Tabel 1. Struktur atribut dataset hasil scraping.

II. Statistik Deskriptif dan Sebaran Data

Karakteristik pemusatan dan penyebaran data dihitung pada 2.000 baris sampel terdepan setelah pra-pemrosesan fitur waktu, sebagaimana disajikan pada Tabel 2.

Atribut	Mean	Median	Std Dev	Min	Max	Q1	Q3	IQR
time_minutes	491,19	497,37	32,87	324,78	541,75	473,08	516,68	43,60
avg_speed_kmh	10,69	10,49	0,98	9,64	16,07	10,10	11,03	0,93
age (tahun)	40,55	40,00	7,61	20,00	69,00	35,00	45,00	10,00
age_graded_min	470,71	475,37	34,77	317,07	536,20	449,70	497,01	47,31

Tabel 2. Ringkasan statistik deskriptif variabel numerik utama.

Pada variabel kecepatan rata-rata (avg_speed_kmh), nilai rata-rata (10,69 km/jam) lebih tinggi daripada median (10,49 km/jam). Selisih ini mengindikasikan distribusi miring ke kanan (positive skewness), di mana sebagian besar pelari terkonsentrasi pada rentang kecepatan 10,0 hingga 11,5 km/jam, sedangkan ekor kanan ditarik oleh performa pelari tercepat yang mencapai 16,07 km/jam. Waktu tempuh tercepat adalah 324,78 menit (5 jam 24 menit 47 detik), sedangkan pelari pada urutan ke-2.000 mencatatkan 541,75 menit (9 jam 1 menit 45 detik).

Komposisi demografis memperlihatkan ketimpangan rasio gender pada kelompok pelari terdepan, yakni 1.895 laki-laki (94,75%) berbanding 105 perempuan (5,25%). Berdasarkan usia, pelari didominasi oleh kelompok usia dewasa matang: kategori M23 (usia 23–34 tahun) mencakup 786 orang (39,30%), disusul M35 sebanyak 454 orang (22,70%), dan M40 sebanyak 346 orang (17,30%). Peserta usia muda di bawah 23 tahun hanya berjumlah 24 orang (1,20%), yang menunjukkan bahwa nomor lomba 87 km didominasi oleh pelari dengan jam terbang ketahanan jangka panjang. Secara geografis, peserta berasal dari tuan rumah Afrika Selatan sebanyak 1.883 orang (94,15%), diikuti Britania Raya (23 orang), Lesotho (14 orang), dan Zimbabwe (12 orang).

III. Kualitas Data dan Penanganan Anomali

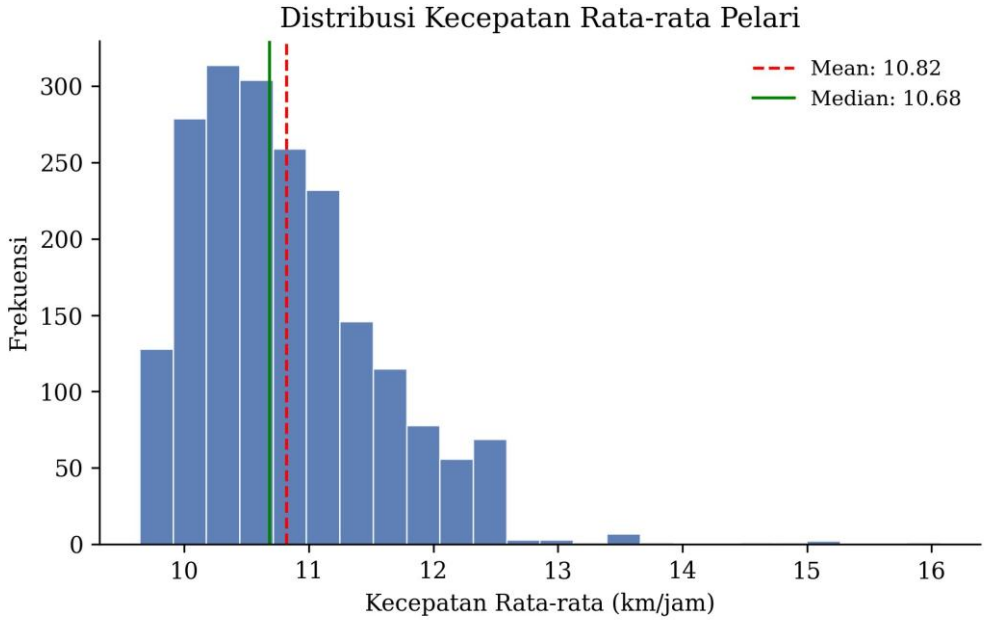
Pemeriksaan integritas data mengidentifikasi dua variabel dengan nilai hilang. Pertama, atribut club memiliki 26 nilai kosong (1,30%). Nilai kosong ini bukan kesalahan sistem, melainkan pelari yang

berpartisipasi secara perorangan tanpa naungan klub resmi (unattached runner). Penanganan dilakukan dengan mengimputasikan label kategorikal ‘Independen’, bukan membuang baris data, sehingga ukuran sampel tetap 2.000 dan perbandingan performa antara pelari berklub dan pelari independen tetap dapat dilakukan. Kedua, atribut age_graded_performance memiliki 8 nilai kosong (0,40%) akibat ketiadaan koefisien faktor usia resmi pada kelompok tertentu; nilai ini diabaikan hanya saat kalkulasi kolom terkait.

Pendeteksian pencilan (outlier) menggunakan metode Interquartile Range (IQR) dengan pagar batas atas Q3 + 1,5 × IQR menghasilkan nilai ambang 12,42 km/jam pada variabel kecepatan. Ditemukan 29 baris data pencilan atas dengan rentang kecepatan 12,43 hingga 16,07 km/jam. Seluruh pencilan tersebut merupakan atlet elit internasional pada peringkat 1 sampai 29 (termasuk juara pertama Leonid Shvetsov). Data pencilan ini diputuskan untuk tetap dipertahankan utuh dalam analisis, karena merupakan variasi performa manusia riil pada ajang kompetitif, bukan galat pengukuran data.

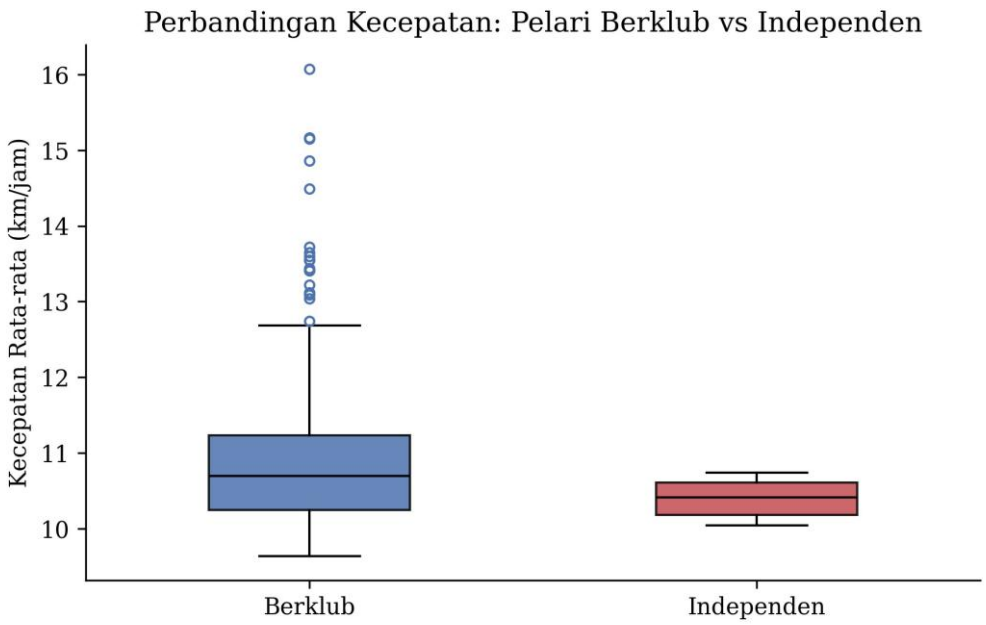
IV. Analisis Visualisasi dan Hubungan Antar-Variabel

Visualisasi data grafis pada Gambar 1 dan Gambar 2 memberikan beberapa temuan analitis utama, yang diuraikan pada bagian berikut.



Gambar 1. Distribusi kecepatan rata-rata pelari (histogram).

Histogram dan garis mean serta median pada Gambar 1 mengonfirmasi bentuk distribusi unimodal yang miring ke kanan. Kepadatan pelari terpadat berada pada rentang 10,0–11,5 km/jam, sedangkan kecepatan di atas 13,0 km/jam bersifat eksklusif bagi segelintir atlet elit podium.



Gambar 2. Perbandingan kecepatan rata-rata antara pelari berklub dan pelari independen (boxplot).

Hasil komparasi bivariat pada Gambar 2 menunjukkan bahwa pelari yang berafiliasi dengan klub memiliki median kecepatan 10,50 km/jam dan mencakup seluruh pencilan kecepatan di atas 13,0 km/jam. Sebaliknya, pelari independen memiliki sebaran yang lebih padat di kecepatan moderat (median 10,39 km/jam, rentang 10,0–10,8 km/jam) tanpa ada yang menembus jajaran elit, mengindikasikan kontribusi pembinaan klub terhadap pencapaian prestasi puncak.

Temuan lain yang diperoleh dari eksplorasi data adalah sebagai berikut.

- **Komparasi gender.** Median kecepatan pelari laki-laki (10,50 km/jam) relatif berimbang dengan median pelari perempuan (10,38 km/jam). Rentang interkuartil kedua kelompok berada pada rentang yang setara (10,1–11,0 km/jam), membuktikan bahwa pelari wanita terdepan memiliki ketahanan kecepatan yang kompetitif.
- **Degradasi performa berdasarkan usia.** Boxplot antar-kelompok umur dan diagram pencar usia versus kecepatan memperlihatkan tren penurunan kecepatan yang bertahap setelah usia 40 tahun. Kategori M23 dan M35 mencatatkan median tertinggi (10,6–10,8 km/jam), sementara kategori M45 dan M50 menurun ke angka 10,2 km/jam.
- **Struktur korelasi linier.** Matriks korelasi Pearson mengonfirmasi hubungan negatif sempurna ($r = -0{,}99$) antara kecepatan rata-rata dan waktu tempuh, konsisten dengan relasi fisika $v = s/t$ pada jarak konstan. Usia menunjukkan korelasi negatif yang lemah terhadap kecepatan ($r = -0{,}18$), menandakan bahwa dalam ultramaraton, usia biologis bukan faktor pembatas mutlak dibandingkan intensitas dan volume latihan aerobik.

V. Kesimpulan

1. Pengumpulan data mandiri melalui web scraping pada basis data DUV berhasil menyusun datasetterstruktur sebanyak 2.000 baris dan 12 atribut tanpa kendala hukum atau etika perayapan.

2. Penanganan nilai kosong pada kolom club melalui imputasi label ‘Independen’ terbuktimempertahankan kelengkapan sampel 2.000 baris dan mengungkap korelasi positif antara afiliasi klub atletik dengan performa pelari elit.

3. Sebanyak 29 pencilan pada variabel kecepatan dipertahankan karena mewakili catatan performasah para pelari terdepan lomba.

4. Profil peserta papan atas didominasi oleh pelari laki-laki (94,75%), kelompok usia dewasa danmaster 23–45 tahun (85,45%), serta berasal dari Afrika Selatan (94,15%).

5. Analisis korelasi membuktikan adanya hubungan terbalik kuat antara kecepatan dan waktu tempuh($r = -0{,}99$), serta korelasi negatif yang lemah antara usia dan performa kecepatan ($r = -0{,}18$).