Tugas Praktikum 5: Sequential Pattern Analysis

Analisis Pola Pembelian Berurutan pada Dataset Online Retail

Nama: Rasya Arya Ramadhan
NRP: 5054251019
Mata Kuliah: Data Mining

1. Pendahuluan

Praktikum ini bertujuan menemukan pola pembelian berurutan (sequential pattern) pada data transaksi ritel online. Pola diekstraksi per pelanggan dengan memperhatikan urutan waktu transaksi, lalu dievaluasi menggunakan metrik support dan confidence. Dataset yang dipakai adalah Online Retail dari UCI Machine Learning Repository, yang berisi 541.909 baris transaksi toko online di Inggris periode Desember 2010 sampai Desember 2011. Hasil akhir berupa daftar pola berurutan yang dapat dimanfaatkan untuk rekomendasi produk, bundling, dan program loyalitas.

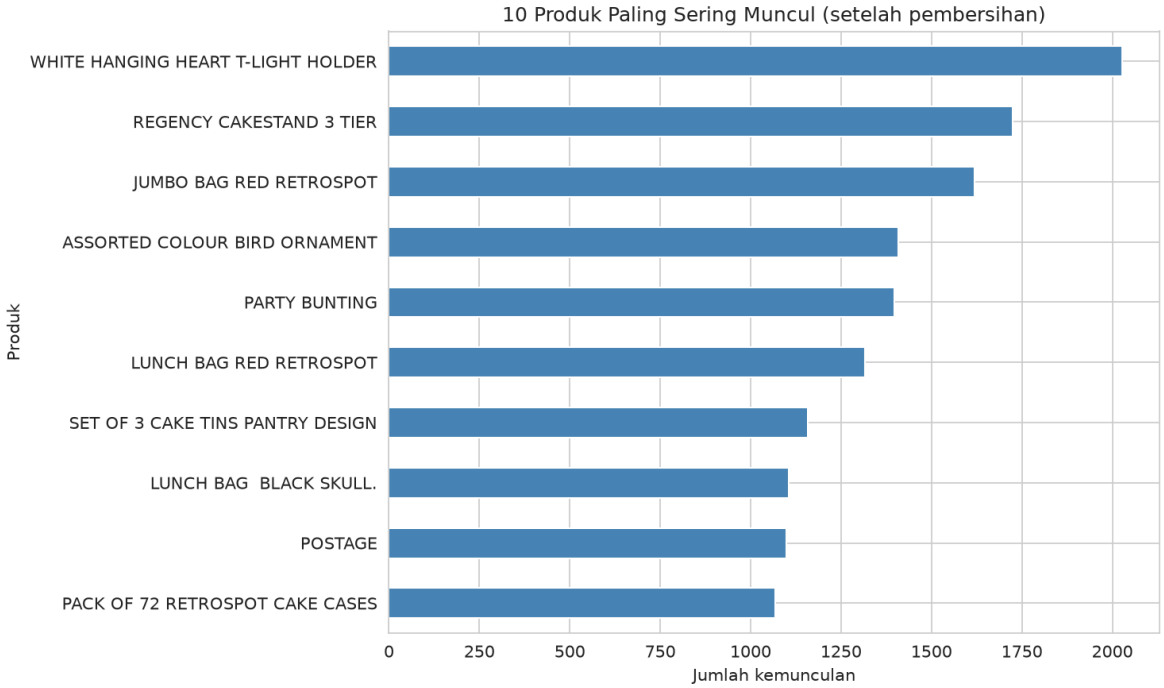
2. Dataset dan Pembersihan Data

Kolom yang paling relevan untuk sequential pattern adalah CustomerID (penanda pelanggan), InvoiceNo (penanda transaksi), InvoiceDate (waktu transaksi), dan Description (item). Pembersihan dilakukan dengan empat aturan: (1) hapus baris dengan Description kosong; (2) hapus transaksi yang dibatalkan, yaitu InvoiceNo yang diawali huruf 'C'; (3) hapus baris dengan Quantity bernilai negatif atau nol; (4) hapus baris dengan CustomerID kosong karena pola dianalisis per pelanggan. Keempat aturan ini dipakai agar transaksi yang dianalisis benar-benar merepresentasikan pembelian nyata.

Kondisi	Jumlah baris	Jumlah invoice	Jumlah pelanggan
Sebelum pembersihan	541,909	25,900	4,372
Sesudah pembersihan	397,924	18,536	4,339

Tabel 1. Jumlah baris, invoice, dan pelanggan sebelum dan sesudah pembersihan.

Setelah pembersihan, 10 produk yang paling sering muncul ditunjukkan pada Gambar 1. Produk-produk seperti WHITE HANGING HEART T-LIGHT HOLDER dan JUMBO BAG RED RETROSPOT mendominasi transaksi, yang menunjukkan produk dekorasi rumah tangga adalah kategori yang paling aktif dibeli.



Gambar 1. Sepuluh produk paling sering muncul setelah pembersihan.

3. Persiapan Sequence

Setiap InvoiceNo dianggap satu itemset (frozenset Description unik). Sequence per pelanggan adalah daftar itemset yang terurut berdasarkan waktu transaksi (InvoiceDate). Duplikat produk dalam satu invoice dihilangkan agar satu item tidak dihitung dua kali. Contoh sequence untuk satu pelanggan ditampilkan pada notebook; secara ringkas, setiap pelanggan memiliki rata-rata 4.96 invoice dengan rata-rata 2.59 item per invoice.

Karena jumlah produk unik sangat banyak (ribuan), item direduksi menjadi 30 produk dengan jumlah pelanggan (customer support) tertinggi. Alasan: pola yang melibatkan produk populer lebih stabil dan dapat ditindaklanjuti secara bisnis, serta runtime mining tetap wajar. Ini adalah reduksi dimensi untuk interpretabilitas. Sequence dibangun ulang hanya dari item top 30; invoice yang kosong dibuang dan pelanggan dengan kurang dari 2 invoice dibuang. Hasilnya tersisa 2,107 pelanggan.

4. Penerapan Algoritma

Miner itemset-aware diimplementasikan sendiri (tanpa library eksternal). Containment: itemset pola $\subseteq$ itemset invoice, dengan indeks invoice naik (subsequence). Enumerasi: panjang 1 {a}; panjang 2 {a,b} (co-occurrence satu invoice) dan {a}->{b} (sekuensial); panjang 3 {a}->{b}->{c} (sekuensial tiga). Support count + support relatif (support_count / n_pelanggan). Confidence untuk pola sekuensial: sup(pola)/sup(prefix); untuk pola single-itemset, confidence = support.

Ambang awal sesuai ketentuan: minsup = ceil(0.01 × n_pelanggan) = 22. Hasil awal menghasilkan 10,724 pola (30 panjang-1, 1.314 panjang-2, 9.380 panjang-3), terlalu banyak untuk ditafsirkan. Karena itu ambang dinaikkan:

- minsup menjadi 0.02 (minimal 43 pelanggan) agar pola lebih umum dan stabil.
- Panjang pola tetap sampai 3 karena dengan minsup 0.02 jumlah pola sudah wajar (2,850).

Alasan penyesuaian: pola dengan support terlalu rendah sering kali hanya kebetulan pada sedikit pelanggan. Pengetatan ini menghasilkan pola yang lebih ringkas tanpa kehilangan pola utama (top pola by support tetap sama).

Skenario	minsup (count)	Jumlah pola
Awal: relatif 0.01	22	10,724
Final: relatif 0.02	43	2,850

Tabel 2. Perbandingan jumlah pola pada dua skenario ambang (n_pelanggan = 2,107).

Breakdown pola final: 30 pola panjang-1, 1.126 panjang-2, dan 1.694 panjang-3. Sepuluh pola dengan support tertinggi (semuanya pola panjang-1, yaitu pembelian berulang item yang sama) ditunjukkan pada Tabel 3.

Pola	Panjang	Support count	Support	Confidence
REGENCY CAKESTAND 3 TIER	1	676	0.3208	0.3208
WHITE HANGING HEART T-LIGHT HOLDER	1	650	0.3085	0.3085
PARTY BUNTING	1	562	0.2667	0.2667
ASSORTED COLOUR BIRD ORNAMENT	1	522	0.2477	0.2477
PACK OF 72 RETROSPOT CAKE CASES	1	521	0.2473	0.2473
JUMBO BAG RED RETROSPOT	1	521	0.2473	0.2473
SET OF 3 CAKE TINS PANTRY DESIGN	1	510	0.2421	0.2421
PAPER CHAIN KIT 50'S CHRISTMAS	1	494	0.2345	0.2345
SPOTTY BUNTING	1	486	0.2307	0.2307
LUNCH BAG RED RETROSPOT	1	472	0.2240	0.2240

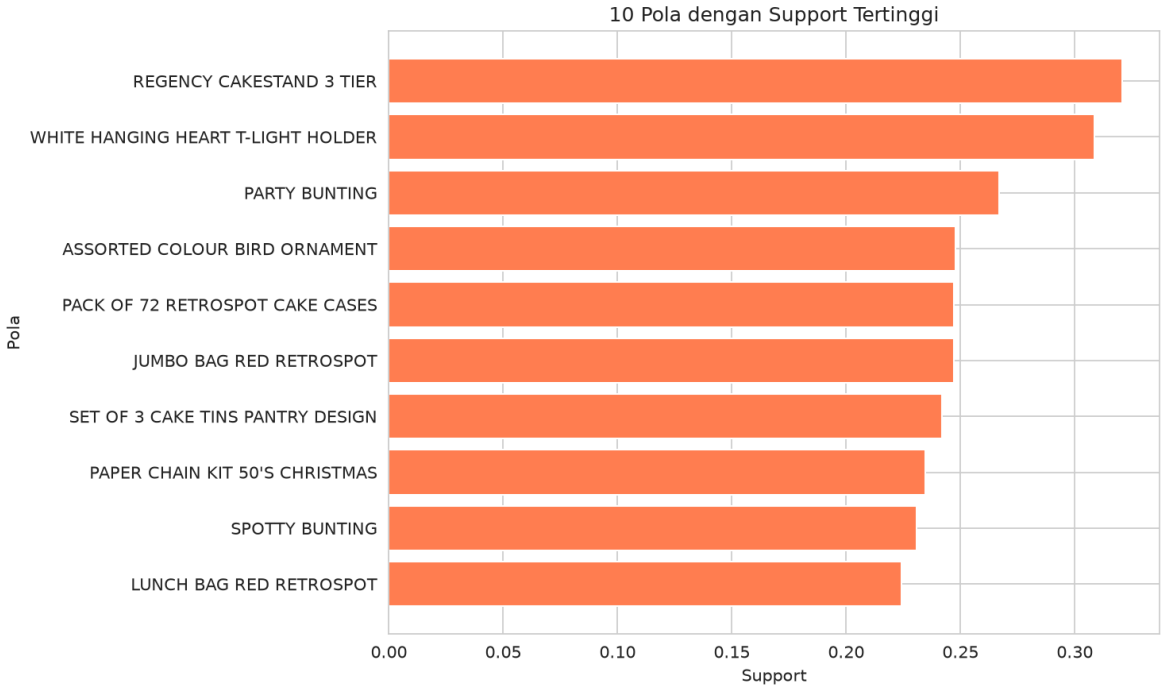
Tabel 3. Sepuluh pola dengan support tertinggi (pola panjang-1).

5. Evaluasi Pola

Metrik yang digunakan: support count (jumlah pelanggan yang mengandung pola sebagai subsequence), support (proporsi pelanggan), confidence (untuk pola sekuensial sup(pola)/sup(prefix); untuk single-itemset = support), dan length (total jumlah item dalam pola).

5.1 Pola dengan Support Tertinggi

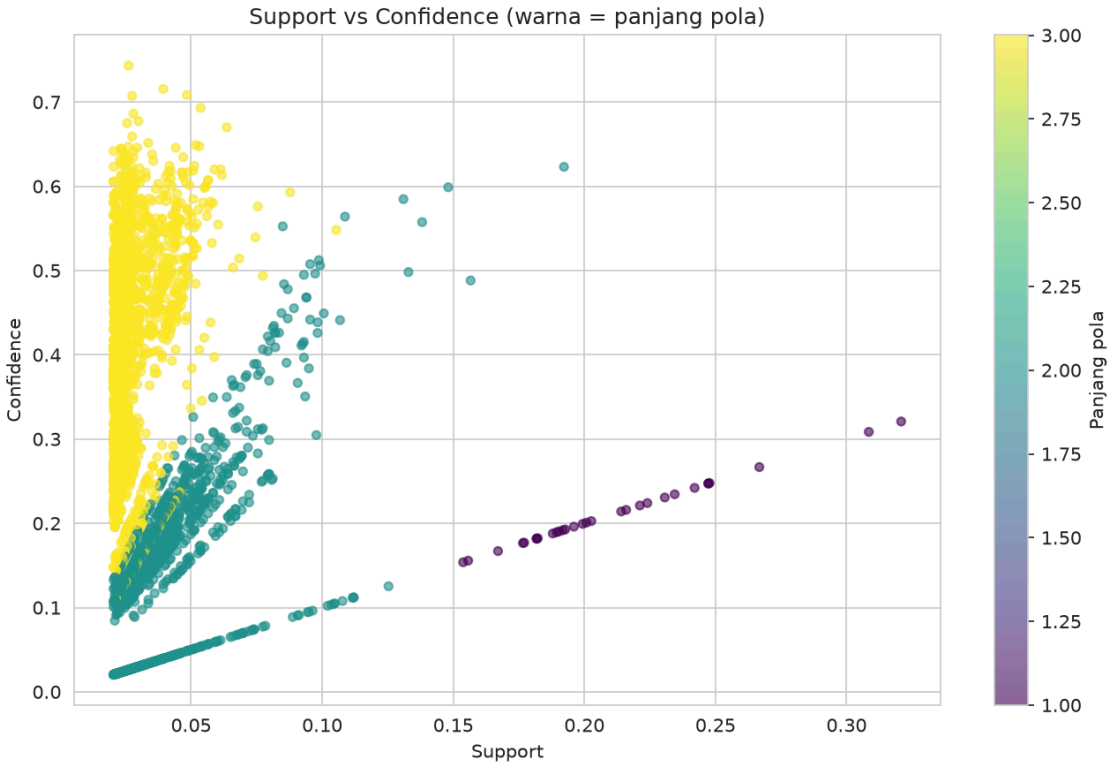
Visualisasi 10 pola dengan support tertinggi ditunjukkan pada Gambar 2. Pola-pola ini didominasi pembelian berulang (repeat purchase) item yang sama oleh pelanggan yang sama pada invoice berbeda.



Gambar 2. Sepuluh pola dengan support tertinggi.

5.2 Sebaran Support vs Confidence

Gambar 3 menunjukkan sebaran support vs confidence dengan warna menunjukkan panjang pola. Pola panjang-1 memiliki support tinggi (0.19-0.32) dan confidence sama dengan support; pola panjang-2 dan panjang-3 memiliki support lebih rendah.



Gambar 3. Sebaran support vs confidence (warna menunjukkan panjang pola).

5.3 Tabel Pola (Top 20 by Support)

Pola	Panjang	Support count	Support	Confidence
REGENCY CAKESTAND 3 TIER	1	676	0.3208	0.3208
WHITE HANGING HEART T-LIGHT HOLDER	1	650	0.3085	0.3085
PARTY BUNTING	1	562	0.2667	0.2667
ASSORTED COLOUR BIRD ORNAMENT	1	522	0.2477	0.2477
PACK OF 72 RETROSPOT CAKE CASES	1	521	0.2473	0.2473
JUMBO BAG RED RETROSPOT	1	521	0.2473	0.2473
SET OF 3 CAKE TINS PANTRY DESIGN	1	510	0.2421	0.2421
PAPER CHAIN KIT 50'S CHRISTMAS	1	494	0.2345	0.2345
SPOTTY BUNTING	1	486	0.2307	0.2307
LUNCH BAG RED RETROSPOT	1	472	0.2240	0.2240
NATURAL SLATE HEART CHALKBOARD	1	466	0.2212	0.2212
HEART OF WICKER SMALL	1	455	0.2159	0.2159
JAM MAKING SET WITH JARS	1	451	0.2140	0.2140
JAM MAKING SET PRINTED	1	427	0.2027	0.2027
LUNCH BAG SPACEBOY DESIGN	1	423	0.2008	0.2008
BAKING SET 9 PIECE RETROSPOT	1	420	0.1993	0.1993
LUNCH BAG CARS BLUE	1	413	0.1960	0.1960
LUNCH BAG BLACK SKULL.	1	406	0.1927	0.1927
WHITE HANGING HEART T-LIGHT HOLDER -> WHITE HANGING HEART T-LIGHT HOLDER	2	405	0.1922	0.6231
SET OF 3 REGENCY CAKE TINS	1	404	0.1917	0.1917

Tabel 4. Dua puluh pola dengan support tertinggi.

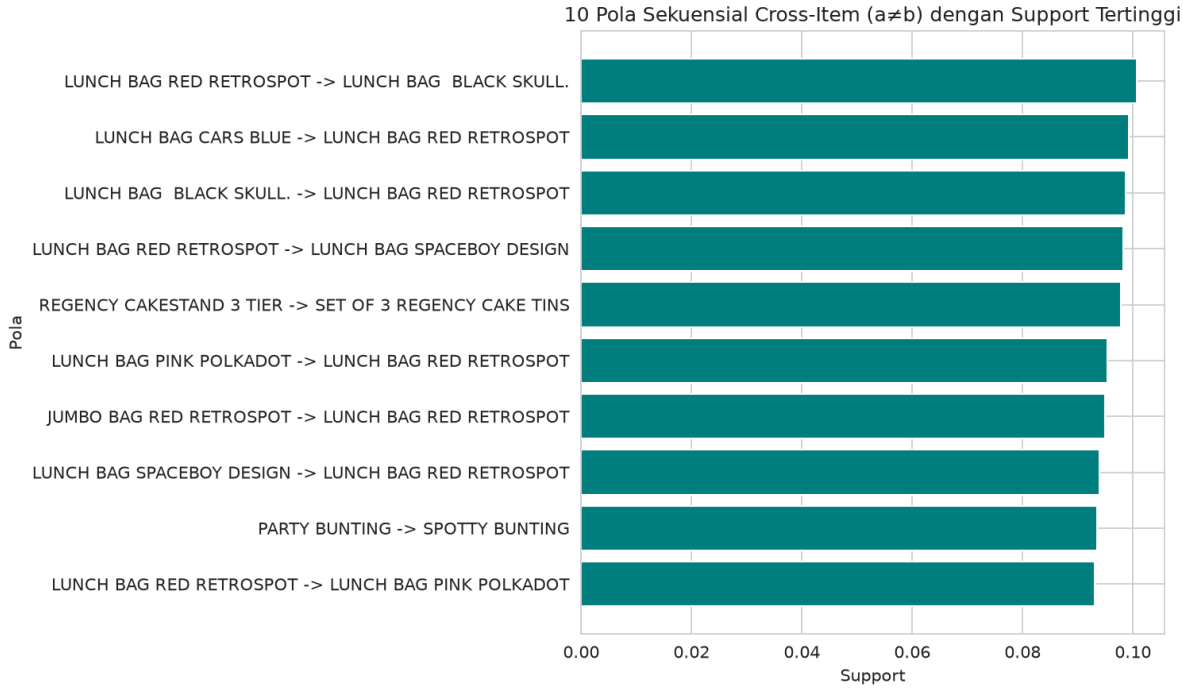
5.4 Pola Sekuensial Cross-Item (a ≠ b)

Untuk insight yang lebih actionable, Tabel 5 dan Gambar 4 menampilkan 10 pola sekuensial dengan item berbeda (a≠b). Pola ini menangkap perilaku "beli A, lalu (pada invoice berikutnya) beli B".

Pola	Panjang	Support count	Support	Confidence
LUNCH BAG RED RETROSPOT -> LUNCH BAG BLACK SKULL.	2	212	0.1006	0.4492
LUNCH BAG CARS BLUE -> LUNCH BAG RED RETROSPOT	2	209	0.0992	0.5061
LUNCH BAG BLACK SKULL. -> LUNCH BAG RED RETROSPOT	2	208	0.0987	0.5123
LUNCH BAG RED RETROSPOT -> LUNCH BAG SPACEBOY DESIGN	2	207	0.0982	0.4386
REGENCY CAKESTAND 3 TIER -> SET OF 3 REGENCY CAKE TINS	2	206	0.0978	0.3047
LUNCH BAG PINK POLKADOT -> LUNCH BAG RED RETROSPOT	2	201	0.0954	0.5076
JUMBO BAG RED RETROSPOT -> LUNCH BAG RED RETROSPOT	2	200	0.0949	0.3839

LUNCH BAG SPACEBOY DESIGN -> LUNCH BAG RED RETROSPOT	2	198	0.0940	0.4681
PARTY BUNTING -> SPOTTY BUNTING	2	197	0.0935	0.3505
LUNCH BAG RED RETROSPOT -> LUNCH BAG PINK POLKADOT	2	196	0.0930	0.4153

Tabel 5. Sepuluh pola sekuensial cross-item (a≠b) dengan support tertinggi.



Gambar 4. Sepuluh pola sekuensial cross-item (a≠b) dengan support tertinggi.

5.5 Tiga Pola Terbaik berdasarkan Support

Tiga pola dengan support tertinggi adalah pola pembelian berulang (repeat purchase) item yang sama oleh pelanggan yang sama pada invoice berbeda. Ini menunjukkan loyalitas produk tertentu.

Interpretasi tiga pola terbaik (by support):

1. **REGENCY CAKESTAND 3 TIER** (support ~0.321): sekitar 32% pelanggan membeli produk ini pada lebih dari satu invoice (repeat purchase). Produk ini adalah salah satu andalan toko; cocok untuk program loyalitas dan re-stocking otomatis.
2. **WHITE HANGING HEART T-LIGHT HOLDER** (support ~0.308): sekitar 31% pelanggan membelinya berulang. Produk dekorasi rumah dengan permintaan stabil; cocok untuk promosi bundling dengan produk sejenis.
3. **PARTY BUNTING** (support ~0.267): sekitar 27% pelanggan membelinya berulang. Produk pesta dengan permintaan berulang; cocok untuk penawaran musiman dan paket pesta.

Ketiganya adalah produk dengan customer support tertinggi (top 30), sehingga wajar mendominasi pola panjang-1. Nilai confidence sama dengan support karena pola single-itemset tidak memiliki antecedent.

Interpretasi pola sekuensial cross-item:

- **LUNCH BAG RED RETROSPOT -> LUNCH BAG BLACK SKULL** (dan sebaliknya) serta variasi lunch bag lain: pelanggan cenderung mengoleksi lunch bag berbagai motif secara

berurutan. Saran bisnis: tampilkan koleksi lunch bag lengkap dan tawarkan bundling "set lunch bag" dengan diskon.

- **REGENCY CAKESTAND 3 TIER -> SET OF 3 REGENCY CAKE TINS** (support ~0.098, confidence ~0.305): pembeli cake stand cenderung kemudian membeli set tin senada. Saran bisnis: rekomendasi "sering dibeli setelahnya" dan bundling peralatan kue.
- **PARTY BUNTING -> SPOTTY BUNTING** (support ~0.093): pembeli bunting pesta cenderung juga membeli spotty bunting. Saran bisnis: penataan produk pesta berdekatan dan paket dekorasi pesta.

Pola-pola ini memiliki support relatif moderat (0.09-0.10) dan confidence 0.3-0.55, artinya berlaku pada segmen pembeli tertentu, cocok untuk rekomendasi terpersonalisasi di toko online.

6. Kesimpulan

- Setelah pembersihan, tersisa 397,924 baris, 18,536 invoice, dan 4,339 pelanggan (dari 541,909 baris, 25,900 invoice, 4,372 pelanggan).
- Sequence dibangun per pelanggan (list of itemset terurut waktu). Setelah reduksi item top 30 dan filter pelanggan dengan <2 invoice, tersisa **2,107 pelanggan**.
- Miner itemset-aware dengan minsup awal ceil(0.01 × n_pelanggan) = 22 menghasilkan **10,724 pola** (terlalu banyak). Ambang dinaikkan ke minsup = 43 (relatif 0.02), menghasilkan **2,850 pola** final (30 panjang-1, 1.126 panjang-2, 1.694 panjang-3).
- Pola dominan adalah pembelian berulang item yang sama (REGENCY CAKESTAND 3 TIER, WHITE HANGING HEART T-LIGHT HOLDER, PARTY BUNTING) dengan support 0.27-0.32.
- Pola sekuensial cross-item yang menarik: LUNCH BAG RED RETROSPOT -> LUNCH BAG BLACK SKULL, dan REGENCY CAKESTAND 3 TIER -> SET OF 3 REGENCY CAKE TINS, dengan support ~0.10 dan confidence ~0.30-0.55.

Secara bisnis, hasil ini dapat dimanfaatkan untuk program loyalitas (repeat purchase), rekomendasi "sering dibeli setelahnya", bundling koleksi (lunch bag, peralatan kue), dan penataan produk (produk dalam satu koleksi berdekatan) pada toko online.